



Les réseaux de neurones convolutifs (CNN)

DAKAR INSTITUTE OF TECHNOLOGY, DIT
COURS DE DEEP LEARNING
PAR MOUSSA DIALLO
INGENIEUR IA, ANSD SENEGAL

Les limites couche linéaires !



Les limites couche linéaires !



- Les couches linéaire:
- Entraînement lent
- Overfitting
- Ne reconnaît pas les caractéristiques dispersée

Introduction aux CNN

Un réseau de neurones convolutif (CNN) est un modèle d'apprentissage profond spécialisé en vision par ordinateur. Il est conçu pour des tâches telles que la classification, la détection et la segmentation d'images.




Par exemple, les CNN sont utilisés dans les véhicules autonomes ou la surveillance vidéo.

Introduction aux CNN


- Les CNN se distinguent des modèles classiques (SVM, perceptron) par leur capacité à apprendre automatiquement des caractéristiques visuelles à grande échelle, sans ingénierie manuelle des features. Ils sont peu sensibles aux translations et variations de l'image, ce qui améliore l'efficacité.

Convolutions : filtres, noyau, stride, padding

- La **convolution** consiste à faire glisser (slide) un petit *filtre* (ou *noyau*) sur l'image d'entrée.
- À chaque position effectué la convolution :
 - on calcule le produit scalaire entre les poids du filtre et la zone correspondante de l'image, produisant ainsi une valeur d'activation locale.
- Le résultat est une **carte d'activation** (feature map).
- Préserve les motifs spatiaux d'entrée
 - Moins de paramètres qu'une couche linéaire
- Ensuite on applique des activations aux cartes
- Toutes les cartes combinées forme la sortie



Convolutions : filtres, noyau, stride, padding



1. Calculer le produit scalaire entre le patch d'entrée (input patch) et le filtre.

○ Case en haut à gauche : $2 \times 1 = 2$

2. Ensuite on fait la somme élément par élément de la matrice obtenue

Convolutions : filtres, noyau, stride, padding

- Convolution

1 _{x1}	1 _{x0}	1 _{x1}	0	0
0 _{x0}	1 _{x1}	1 _{x0}	1	0
0 _{x1}	0 _{x0}	1 _{x1}	1	1
0	0	1	1	0
0	1	1	0	0


Image

4		


Convolved
Feature

Fonctionnement des filtres et cartes d'activation

- Chaque couche convolutive contient plusieurs filtres apprenables.
- Chaque filtre est spécialisé pour détecter un type de motif (bords, textures, etc.)
- L'application de K filtres sur une entrée 3D de dimension $W \times H \times D$ produit un volume de sortie $W' \times H' \times K$.
- $W' = \frac{W-F+2P}{S} + 1$
- $H' = \frac{H-F+2P}{S} + 1$
- $D = K$
- Par exemple, 12 filtres 3×3 sur une image $32 \times 32 \times 3$ donnent en sortie un volume $32 \times 32 \times 12$ si $P=1$ et $S=1$.



Convolutions : filtres, noyau, stride, padding




- **Pas (stride)** – Le *stride* contrôle l'écart de déplacement du filtre. Un stride de 1 fait avancer le filtre d'un pixel à chaque étape, tandis qu'un stride de 2 saute d'un pixel (voir ci-dessous). Un stride plus grand réduit la taille spatiale de la sortie

Convolutions : filtres, noyau, stride, padding


- **Padding** – Pour conserver la taille de l'image, on peut ajouter des zéros en bordure (*padding*). Par exemple, un padding de
- $P = \frac{F-1}{2}$ et $S=1$
- (avec F la taille du filtre) permet de garder l'entrée et la sortie de même taille spatiale.

0	0	0	0	0	0
0					0
0					0
0					0
0					0
0	0	0	0	0	0

Pooling (max, average)



Max Pooling



Select the maximum value from each window.


- Le max pooling consiste à glisser une fenêtre (typiquement 2×2) sur chaque carte d'activation et à retenir la valeur maximale dans chaque fenêtre.
- Cette opération réduit la résolution spatiale tout en conservant les caractéristiques les plus saillantes
- Average pooling – Fonctionne de manière similaire mais prend la moyenne des valeurs du bloc 2×2.
- Le pooling apporte invariance aux petites translations de l'image et réduit le nombre de paramètres, ce qui accélère le calcul et diminue le risque de surapprentissage

Activation et Pooling

- Activation ReLU : $\max(0, x)$, introduit la non-linéarité, évite saturation.
- Pooling : Réduit la dimension spatiale, conserve l'essentiel.
- Max-Pooling : fenêtre 2×2 , $\text{stride}=2 \rightarrow$ divise H et L par 2.
- Nombre de canaux reste inchangé.
- Avantage : robustesse aux petites translations, moins de calcul.

Architecture typique d'un CNN

Un CNN typique alterne plusieurs fois les blocs Conv $\rightarrow$ ReLU $\rightarrow$ Pooling




- Un CNN typique alterne plusieurs fois les blocs *Conv* $\rightarrow$ *ReLU* $\rightarrow$ *Pooling*. On part de l'entrée (image brute), puis chaque bloc convolutif (avec activation ReLU) extrait des cartes de caractéristiques, suivi d'une couche de pooling pour réduire la taille spatiale
- Après plusieurs étapes convolution-pooling, on *aplatie* (flatten) le volume final en un vecteur, qui est passé dans une ou plusieurs couches **entièrement connectées** (fully connected) pour la classification finale

Couches Fully Connected (FC) et Sortie




- Flatten : transforme feature maps 2D en vecteur 1D.



- Couches FC : connectées à toutes les valeurs → classification finale.



- Couche de sortie : nombre de neurones = nombre de classes.



- Softmax : convertit scores en probabilités (somme=1).

Architecture Typique d'un CNN

1. Entrée (ex. 32x32x3)

2. Conv + ReLU → features locales

3. Pooling → réduit taille

4. Répétition de blocs Conv/ReLU/Pooling


5. Flatten → vecteur

6. Fully Connected → combine features

7. Sortie Softmax → classification

→ Réduction spatiale + augmentation de profondeur.

Exemple : Architecture LeNet-5



Conclusion et Points Clés

- • CNN = efficacité grâce au partage des poids.
- • Pooling : invariance locale, robustesse.
- • Flatten : réduction spatiale, augmentation profondeur.
- • FC : classification finale.
- → CNN adaptés aux images, plus performants que réseaux denses classiques.

EXERCICE

- Considérons les couches suivantes et spécifions la forme (shape) de la couche de sortie à la fin de toutes les transformations, en supposant une image d'entrée de taille $256 \times 256 \times 3$:
- **### Travail demandé :**
- Calculez, étape par étape, la taille de la sortie (hauteur $\times$ largeur $\times$ profondeur) après chaque couche.
- Autrement dit, indiquez la forme finale de la matrice de sortie à la fin de la quatrième couche.
- 1. Une couche de convolution avec 16 filtres de taille 3, un stride (pas) de 1 et un padding (remplissage) de 1.
- 2. Une couche de pooling avec un filtre de taille 2 et un stride de 2.
- 3. Une couche de convolution avec 8 filtres de taille 7, un stride de 1 et un padding de 3.
- 4. Une couche de pooling avec un filtre de taille 2 et un stride de 2.